

《人工智能导论》

期末复习讲义

基于《人工智能导论-习题汇总-v6》

涵盖全部知识点与典型习题解析

共 360 道经典习题 • 10 大知识模块

2026 年 6 月 7 日

本讲义系统梳理课程全部核心知识点，适合期末复习使用。

目 录

1	人工智能概论与发展历史	4
1.1	核心概念	4
1.1.1	图灵测试 (Turing Test)	4
1.1.2	人工智能发展历程	4
1.1.3	人工智能三大学派	4
1.1.4	重要时间线	5
1.1.5	AI 发展关键模型时间线	5
1.1.6	新一代人工智能	5
2	脑与认知科学基础	6
2.1	神经系统基础	6
2.1.1	神经元	6
2.1.2	脑结构	6
2.1.3	大脑”三沟五叶”	6
2.2	视觉系统	7
2.2.1	视觉信息处理	7
2.2.2	视觉双通路	7
2.3	听觉与语言系统	7
2.4	记忆与情绪	7
2.5	脑科学与 AI 技术	8
3	人工神经网络发展史	9
3.1	M-P 模型与感知机	9
3.2	BP 算法 (反向传播)	9
3.3	从 CNN 到 Transformer	9
3.3.1	卷积神经网络 (CNN)	9
3.3.2	循环神经网络 (RNN) 与 LSTM	10
3.3.3	Transformer	10
3.4	重要人物与奖项	10
3.5	深度学习框架	10
4	机器学习基础	12
4.1	基本概念	12
4.2	学习类型	12

4.3	回归与分类	12
4.4	梯度下降	13
4.5	模型评估与选择	13
4.5.1	数据集划分	13
4.5.2	过拟合与欠拟合	13
4.5.3	评估方法	13
4.5.4	评价指标	14
4.6	无监督学习——K 均值聚类	14
5	深度学习详解	15
5.1	人工神经网络基础	15
5.2	关键算法深度解析	15
5.2.1	BP 算法要点回顾	15
5.2.2	CNN 深度解析	15
5.3	GAN、强化学习等高级模型	15
6	计算机视觉	16
6.1	任务与应用	16
6.2	目标检测模型	16
6.2.1	关键算法对比	16
6.3	评价指标	16
6.4	传统 vs 深度学习方法	17
6.5	关键模型里程碑	17
7	自然语言处理与大语言模型	18
7.1	语言模型基础	18
7.2	词向量 (Word Embedding)	18
7.3	大语言模型 (LLM)	18
7.3.1	核心概念	18
7.3.2	Transformer 架构	18
7.4	幻觉问题 (Hallucination)	19
7.5	RAG: 检索增强生成	19
7.6	关键模型	19
8	知识图谱	20
8.1	定义与组成	20
8.2	构建与应用	20
8.3	与符号主义的关系	20

9	强化学习与智能体	21
9.1	莫拉维克悖论	21
9.2	强化学习 (Reinforcement Learning)	21
9.2.1	核心概念	21
9.2.2	马尔可夫决策过程 (MDP)	21
9.2.3	策略与价值	21
9.3	智能体 (Agent)	22
9.3.1	智能体定义与属性	22
9.3.2	PEAS 任务环境描述	22
9.3.3	环境类型分类	22
9.3.4	智能体类型	23
9.4	机器人	23
10	人工智能安全与伦理	25
10.1	AI 风险分类	25
10.2	核心概念详解	25
10.2.1	鲁棒性 (Robustness)	25
10.2.2	可解释性 (Explainability)	25
10.2.3	公平性 (Fairness)	25
10.2.4	隐私性 (Privacy)	26
10.3	攻击方式	26
10.4	风险防范技术	26
10.5	伦理治理原则	26
10.5.1	超级对齐	27
11	附录：重要人物与时间线	28
11.1	重要人物一览	28
11.2	关键事件时间线	29
12	附录：易错题重点提示	30
	考前温馨提示	32

人工智能概论与发展历史

核心概念

人工智能 (Artificial Intelligence): 研究如何让计算机模拟、延伸和扩展人类智能的理论、方法及应用系统的学科。

图灵测试 (Turing Test)

- 提出者:** 艾伦·图灵 (Alan Turing), 1950 年发表论文《计算与智能》
- 测试方法:** 如果超过**30%**的测试者无法分辨被测试对象是人还是机器, 则认为机器具有智能
- 图灵机组件:** 读写头、控制器、卡带 (不包括仿真器)

人工智能发展历程

阶段	时间	关键事件
诞生	1956 年	达特茅斯会议——”人工智能”概念诞生
第一次崛起	1950s-60s	符号主义兴起, 专家系统出现
第一次低谷	1970s	感知机局限性被指出 (明斯基 & 派珀特, 《感知器》)
第二次崛起	1980s	专家系统 (符号主义), Hopfield 网络
第二次低谷	1980s 末	专家系统局限性暴露
第三次崛起	2010s	深度学习 + 大数据 + GPU 算力

截至目前, 人工智能经历了**两次**低谷; ”AlphaGo” 称霸围棋是**第三次**AI 崛起的典型示例。

人工智能三大学派

学派	英文	起源	代表性成果
符号主义	Symbolism	数理逻辑、逻辑推理	专家系统、知识图谱
连接主义	Connectionism	仿生学、人脑模型	感知机、深度学习
行为主义	Behaviorism	控制论	强化学习、机器人

- 符号主义：主张从**功能模拟**入手
- 连接主义：主张从**结构设计**入手
- 行为主义：主张通过**环境反馈**实现智能进化
- 生成主义（Generativism）**不属于**三大学派

重要时间线

- 摩尔定律：PC 芯片每 **18** 个月性能提升一倍
- **2012 年**：AlexNet 在 ILSVRC 夺冠，开启深度学习浪潮
- **2016 年 3 月**：AlphaGo 以 4:1 击败李世石
- **2017 年**：国务院印发《新一代人工智能发展规划》
- **2020 年**：中国进入大模型快速发展期

AI 发展关键模型时间线

- 最早被提出的深度学习模型：**AlexNet**（2012）
- 最早被提出的大模型：**BERT**（2018）
- GPT-2 参数量：**15 亿**级别
- DeepSeek-R1 强调：**推理与思维链**（DeepSeek 不完全闭源）

新一代人工智能

- **三元空间**：信息网络、人类、物理（**不包括**仿生学）
- **战略布局基础理论**：大数据智能、人机混合智能、群体智能（**不包括**初级机器学习）
- **大数据智能层级**：数据 → 知识 → 决策
- **核心三要素**：数据、算法（模型）、算力（**不包括**操作系统）

本模块核心考点：图灵测试年份与阈值、AI 三大学派及对应成果、AI 发展三次崛起与两次低谷、关键模型（AlexNet/AlphaGo/BERT/DeepSeek）的时间与特征、新一代 AI 三元空间与战略布局。

脑与认知科学基础

神经系统基础

神经元

- 基本单元：神经系统由**神经元**组成
- 人类大脑神经元数量：约 **860 亿**
- 神经连接数量：约 **100 万亿** 条
- 神经元结构：树突 + 细胞体 + 轴突
- 树突**接受**刺激（神经冲动），轴突**传出**刺激
- **突触（Synapse）**：由 C.S. Sherrington 1897 年提出，是神经元间的接触部位，负责信息传递

脑结构

结构	特征	功能
灰质	颜色深、褶皱、厚 2-3cm、面积约 2200cm ²	神经细胞最集中区域，智能来源
白质	皮层下面	轴突所在，大脑” 通信网络”
脑脊液	充满脑室系统	缓冲保护、提供营养、带走废物

大脑” 三沟五叶”

- 五叶：额叶、顶叶、颞叶、枕叶、岛叶
- 视觉皮层位于**枕叶**（V1 区 / 初级视觉皮层）
- 听觉功能主要位于**颞叶**
- 语言功能主要位于**左半球大脑**

视觉系统

视觉信息处理

- 大卫·休伯尔 & 托斯坦·维瑟尔：猫的视觉皮层中简单细胞和复杂细胞通过**卷积**和**下采样**进行**分层**处理
- 受此启发 → 福岛邦彦设计 **Neocognitron**（现代 CNN 雏形）
- 简单细胞：提取**特定朝向的边缘信息**
- 复杂细胞：整合局部信息形成**高级视觉表示**

视觉双通路

- **腹侧通路（What 通路）**：物体**内容**的感知和识别
- **背侧通路（Where 通路）**：物体**空间位置**的感知和识别
- 物体识别的**特异性加工理论**：大脑中存在专门加工特定类别物体的脑区

听觉与语言系统

- **腹侧听觉通路（What）**：声音**内容**识别
- **背侧听觉通路（Where）**：声音**定位**
- **Broca 脑区**：在**语法加工**中起重要作用
- **Wernicke 脑区**：在**语义理解**中起重要作用

记忆与情绪

- **记忆三类型**：感觉记忆 → 短时记忆（几秒到几分钟） → 长时记忆（几天到数十年）
- **海马体**：记忆形成的**关键区域**
- **杏仁核**：情绪（特别是**恐惧情绪**）的**核心脑区**
- **情绪三部分**：主观体验、生理反应、行为表现

脑科学与 AI 技术

- **脑解码**：通过分析大脑神经活动信号获取心理状态/感官/行为信息
- **类脑计算**：借鉴大脑结构和功能开发计算系统
- **脑机接口 (BCI)**：在大脑和外部设备间建立通信和控制

本模块核心考点：神经元结构与数量、灰质/白质/脑脊液功能、五叶分工、视觉双通路 (What/Where)、听觉双通路、Broca/Wernicke 脑区、三类记忆、海马体与杏仁核功能、脑解码/类脑计算/脑机接口定义。

人工神经网络发展史

M-P 模型与感知机

- **M-P 模型** (1943): 麦卡洛克 & 皮茨, 受神经元细胞结构启发, 现代 ANN 基础
- **M-P 神经元构成**: 输入权重、阈值、激活函数 (不包括池化核)
- **Hebb 学习规则** (1949): 早期训练算法, 但缺乏明确误差修正机制, 容易权重无限增长
- **感知机** (1957, 罗森布拉特): 第一个具有学习能力的算法模型
- **单层感知机局限**: 无法解决**异或 (XOR) 问题** (线性不可分)

BP 算法 (反向传播)

- **核心数学原理**: **链式法则**
- 1986 年 Rumelhart、Hinton、Williams 提出
- **基本思路**: 在 学习基础上进行多层扩展
- **算法流程**: 正向传播预测 → 计算输出误差 → **梯度下降**更新权重
- **常用误差函数**: 均方误差 (MSE)
- **BP 算法局限性**: 梯度消失、过拟合、局部极值

深层网络使用 BP 训练最易出现**梯度消失**问题——随着隐含层增加, 反向传播传递给较低层的信息减少。

从 CNN 到 Transformer

卷积神经网络 (CNN)

- **Neocognitron** (1980, 福岛邦彦): CNN 雏形
- **LeNet-5** (1989, 杨立昆): 反向传播 + CNN → 最早实际应用的 CNN
- **AlexNet** (2012): ILSVRC 冠军 (领先第二名 10.8 个百分点), 开启深度学习浪潮

- **CNN 核心特性**：局部连接、权值共享、池化降维
- **池化层作用**：降低空间维度、增强平移不变性、减少参数量
- **ReLU 激活函数**：缓解梯度消失、简化计算、加速训练（但不能彻底解决死亡神经元问题）
- **ResNet (2015)**：跳跃连接（残差连接），解决深层网络退化问题，152 层

循环神经网络 (RNN) 与 LSTM

- **RNN**：通过隐藏状态（hidden state）传递时间信息，适合时序序列数据
- **CNN 局限**：未考虑时序变化，难以捕捉长期依赖
- **LSTM (1997)**：引入门控机制（遗忘门、输入门、输出门），缓解梯度消失/爆炸

Transformer

- 2017 年 Google 提出，核心：**自注意力机制**
- **位置编码**：为并行化注意力机制引入位置信息
- **BERT**：双向 Transformer 编码器
- **GPT**：自回归方式预测下一个词
- **ViT**：将图像分割为固定大小 Patch 输入 Transformer

重要人物与奖项

- **2024 年诺贝尔物理学奖**：约翰·霍普菲尔德 & 杰夫·辛顿，“基于人工神经网络实现机器学习的基础性发现和发明”
- **通用/万能近似定理**：至少需一个隐藏层即可逼近任意连续函数

深度学习框架

- **PyTorch**：动态计算图，便于快速原型设计
- **TensorFlow**：TensorBoard 可视化
- **飞桨 (PaddlePaddle)**：百度开发，中国首个自主研发产业级平台
- **昇思 (MindSpore)**：华为全场景 AI 框架

本模块核心考点：M-P 模型、单层感知机与 XOR 问题、BP 算法（链式法则）、CNN 核心特性、ReLU 优势/局限、ResNet 跳跃连接、RNN 隐藏状态传递、LSTM 门控机制、Transformer 自注意力、GPT/BERT/ViT 特点、深度学习框架对比。

机器学习基础

基本概念

- 机器学习定义（亚瑟·塞缪尔）：让计算机无需显式编程即可学习
- 形式化定义（汤姆·米切尔）：程序通过经验提升任务性能
- 核心要素：数据、模型、**目标函数**（损失函数）、优化算法
- 与传统编程的区别：机器学习通过数据自动生成规则，而非人工编写规则
- 核心目标：**泛化能力**——对未知数据做出准确预测

学习类型

类型	数据要求	典型应用
监督学习	标注数据	房价预测、图像分类
无监督学习	无标签数据	客户聚类、数据降维
半监督学习	部分标注	网页分类
弱监督学习	粗粒度标签	仅知图片是否含动物
强化学习	环境交互反馈	游戏、机器人控制

- 监督学习 *vs* 非监督学习根本区别：**是否依赖标注数据训练**
- 强化学习与监督学习**有关联**（不是完全独立）

回归与分类

- 回归：预测连续值（如房价），由弗朗西斯·高尔顿提出
- 逻辑回归：主要用于**二分类**任务
- Sigmoid 函数：将线性输出转换为**概率值** (0, 1)
- 线性回归梯度：若 MSE 对 w 偏导数为正，应**减小** w 以减小误差

梯度下降

- 沿梯度反方向调整参数以减小损失
- 适用于深度学习，但不仅限于线性模型
- 为什么不用直接求导：计算复杂度过高或缺乏解析解
- BGD *vs* SGD: BGD 使用全部样本更新参数，SGD 使用单个样本

模型评估与选择

数据集划分

- 训练集：拟合模型参数
- 验证集：调整超参数、模型选择
- 测试集：最终评估泛化能力
- 要求：三者数据分布一致

过拟合与欠拟合

状态	训练误差	测试误差
欠拟合	高	高
过拟合	低	高
理想状态	低	低

- 缓解过拟合：增加训练数据、L2 正则化、Dropout、早停、交叉验证
- 采用更复杂网络 → 加重过拟合！
- 缓解欠拟合：增加模型复杂度、减小正则化系数、特征工程（早停不能缓解欠拟合）

评估方法

- 留出法：简单划分，适合快速验证大数据集
- K 折交叉验证：减少数据划分的随机性影响，非单次划分
- 奥卡姆剃刀原则：在满足需求时优先选择更简单的模型

评价指标

- **TP/FP/FN/TN**：混淆矩阵四要素
- **精确率 (Precision)** = $TP / (TP + FP)$ —— 预测为正中真正为真的比例
- **召回率 (Recall)** = $TP / (TP + FN)$ —— 真正为正中被正确识别的比例
- **F1 分数**：精确率与召回率的调和平均数，对不平衡数据有参考价值
- **医疗筛查**：优先保证高召回率（避免漏诊）

无监督学习——K 均值聚类

- **步骤顺序**：初始化中心 → 分配样本 → 更新中心 → 迭代
- **优化目标**：最小化簇内距离平方和

本模块核心考点：监督/无监督/半监督/弱监督学习区别、过拟合与欠拟合表现及对策、交叉验证原理、精确率/召回率/F1、奥卡姆剃刀、BGD 与 SGD 区别、逻辑回归与 Sigmoid、K 均值步骤。

深度学习详解

人工神经网络基础

- 深度学习核心：模拟大脑神经网络
- 训练本质：调整神经元连接权重
- 与生物神经网络共同点：神经元连接强度可调
- 现代 ANN 仿生：生物神经元与突触结构

关键算法深度解析

BP 算法要点回顾

- 核心：在 学习基础上进行多层扩展
- 通过链式法则计算误差对每层权重的梯度
- 算法流程（不包括 Hebb 法则更新权重）
- 参数数量随网络规模平方级增长（计算缺点）
- M-P 模型用阶跃函数 → 等价于线性分类器

CNN 深度解析

- 端到端学习：单一模型直接处理，自动学习特征，无需人工干预
- 池化操作带来：平移/旋转/尺度不变性
- 对计算机视觉贡献：自动学习图像特征
- CNN 未考虑时序变化 → 不适合处理强时序相关性序列问题

GAN、强化学习等高级模型

- AlphaGo：深度神经网络 + 强化学习
- 利用 CNN 特征提取 + 强化学习决策能力

计算机视觉

任务与应用

应用领域	核心任务
自动驾驶	实时检测行人、车辆、交通标志
遥感分析	地表覆盖分类、灾害监测、舰船/风力发电识别
医疗影像	辅助诊断（挑战：数据隐私、可解释性、标注稀缺）
文字识别 (OCR)	图像边缘检测与字符分割
增强现实 (AR)	实时跟踪物体位置与姿态（+ SLAM）
人脸识别	身份验证（挑战：光照、姿态、年龄变化）

目标检测模型

关键算法对比

算法	类型	核心创新	特点
R-CNN	两阶段	Selective Search + CNN + SVM	速度慢、精度较高
Fast R-CNN	两阶段	ROI Pooling 共享卷积特征	比 R-CNN 快
Faster R-CNN	两阶段	RPN 替代 Selective Search	精度高
YOLO	单阶段	网格划分 + 单次回归	速度快 、小目标效果差
Mask R-CNN	两阶段	检测 + 分割	目标检测 + 实例分割

YOLO 将图像划分为网格，每个网格预测多个边界框，将目标检测转化为**单次回归问题**。缺点是对**小目标**和**密集目标检测效果较差**。

评价指标

- IoU（交并比）**：衡量预测区域与真实区域的重叠程度
- AP（Average Precision）**：衡量模型对每个类别的检测精度
- mAP（mean Average Precision）**：所有类别 AP 的平均值

传统 vs 深度学习方法

- 传统方法 (SIFT、HOG): 依赖手工设计, 泛化能力弱
- 深度学习 (CNN): 自动学习多层次空间特征
- 传统人脸检测局限: 静态特征设计、缺乏层次化语义表征、极度依赖人工经验

关键模型里程碑

- LeNet-5: 现代 CNN 真正开端
- AlexNet: 开启深度学习大规模应用浪潮
- ViT: 首次将 Transformer 引入计算机视觉

本模块核心考点: CNN 端到端学习、池化层不变性、R-CNN 系列演进 (RPN)、YOLO 单阶段原理与缺点、Mask R-CNN、IoU/AP、传统 vs 深度学习特征、Computer Vision 主要应用场景。

自然语言处理与大语言模型

语言模型基础

- 核心目标：预测一段文本的概率分布
- 自回归语言模型：当前输出仅依赖于之前的输出
- 处理不确定性：对输出进行概率建模
- 自然语言处理目标：让计算机能够理解和生成人类语言

词向量（Word Embedding）

- 核心目标：在低维连续向量空间中捕捉词语的语义和语法关系
- 将词语转换为计算机可理解的数值向量
- 有利于进行语义相似性计算
- 余弦相似度：衡量词语的语义相似性（非拼写相似性）

大语言模型（LLM）

核心概念

- 尺度定律（Scaling Law）：大模型参数数量与效果的关系
- 预训练阶段：学习海量无标注文本中的语言规律
- 指令微调：帮助模型理解用户意图
- 涌现能力：模型参数量达到阈值后突然具备新能力
- GPT 特点：基于自回归生成（逐词生成文本）

Transformer 架构

- 核心：注意力机制（Attention）
- 编码器-解码器注意力层：允许解码器关注编码器的输出
- 掩码自注意力：防止未来位置信息流入当前位置（解码器）

幻觉问题（Hallucination）

- 定义：模型生成与输入无关的**虚假信息**
- 根本原因：训练数据与真实世界知识存在偏差（含噪声或错误信息）
- 最严重影响：**医疗诊断建议生成**
- 缓解方法：
 - 引入外部知识库进行事实性验证
 - **RAG（检索增强生成）**：结合检索外部知识库与生成模型
 - 提示策略：明确要求”仅基于可信来源回答”

RAG：检索增强生成

- 核心思想：结合检索外部知识库与生成模型的能力
- 工作流程两阶段：**检索** → **生成**
- 相比纯生成模型优势：提高生成内容的**事实准确性**
- RAG 不依赖模型自身参数，需引入外部知识库

关键模型

- **BERT**：双向 Transformer 编码器（2018 年，最早的大模型）
- **GPT 系列**：自回归方式、逐词生成
- GPT-1 → GPT-2（15 亿参数）→ GPT-3 → ChatGPT
- 2020 年：中国进入大模型快速发展期

本模块核心考点：词向量目标与余弦相似度、大模型尺度定律、涌现能力、预训练本质、Transformer 注意力机制、幻觉问题（原因/影响/缓解）、RAG 原理与优势、BERT 与 GPT 区别。

知识图谱

定义与组成

- 定义：结构化的语义知识库，将知识以图的形式存储
- 核心目标：通过结构化语义网络描述实体及其关系
- 表现形式：有向图
- 主要组成部分：节点（实体）、边（关系）、关系事实
- 本体（Ontology）：定义实体类别与关系的逻辑约束（属于模式层，不是数据层组件）
- 实体不可以是”某人出生于某地”（这是关系事实，不是实体）
- 实体可以是：实例、数值、时间

构建与应用

- 关键步骤：实体识别 → 关系抽取 → 知识融合（不包括图像分类）
- 最适合数据库：图数据库（如 Neo4j）
- 典型应用：智能问答系统（如谷歌搜索）
- 与传统数据库核心区别：强调实体间的语义关联

与符号主义的关系

- 知识图谱是人工智能符号主义学派的代表性成果
- 符号主义起源于数理逻辑和逻辑推理

本模块核心考点：知识图谱定义（有向图）、本体概念、构建步骤、图数据库存储、与符号主义关系、三元组表示（头实体-关系-尾实体）。

强化学习与智能体

莫拉维克悖论

- 核心观点：对人类来说简单的感知和运动技能，机器实现起来反而比高级推理困难
- 典型例子：机器人依靠复杂技术完成叠衣服这一简单任务
- 提出者不包括：艾伦·图灵（包括汉斯·莫拉维克、罗德尼·布鲁克斯、马文·明斯基）

强化学习（Reinforcement Learning）

核心概念

- 核心机制：通过试错和奖励信号调整策略
- 最终目标：最大化**累计折扣奖励**
- 与监督学习区别：强化学习依赖试错和延迟奖励
- 深度强化学习：使用神经网络处理高维和连续的状态输入

马尔可夫决策过程（MDP）

- 五元组：状态空间 (S)、动作空间 (A)、奖励函数 (R)、状态转移概率 (P)、折扣因子 (γ)
- 不包括：学习率 (α)
- 折扣因子 γ ：调节当前奖励与未来奖励的重要性

策略与价值

- 策略 (Policy)：定义状态到动作的映射
- AlphaGo：强化学习 + 深度学习的结合
- HumanPlus：使用近端策略优化 (PPO) 算法

智能体（Agent）

智能体定义与属性

- 智能体：通过传感器感知环境并通过执行器对环境进行作用的主体
- 智能体规则：识别环境 → 根据观察决定 → 导致行动（行动不能是随意的）
- 理性不取决于：自身动作的随机性（取决于性能度量、先验知识、感知序列）
- 理性智能体不能保证完美结果——它只基于有限信息做最优决策

PEAS 任务环境描述

- Performance measure（性能度量）
- Environment（环境）
- Actuators（执行器）
- Sensors（传感器）
- 不包括：状态空间、医生的行医执照

环境类型分类

维度	分类
可观察性	完全可观察 <i>vs</i> 部分可观察
确定性	确定性 <i>vs</i> 随机性
片段性	片段式 <i>vs</i> 序列式
动态性	静态 <i>vs</i> 动态
连续性	离散 <i>vs</i> 连续
智能体数量	单智能体 <i>vs</i> 多智能体

环境分类实例：

- 围棋 AlphaGo: **完全可观察**、确定性、序列式、静态、离散
- 自动驾驶: **部分可观察**、随机性、**序列式**（非片段式）、动态、连续、多智能体
- 零件挑选机器人: **动态环境**
- 医疗诊断: **部分可观察环境**

智能体类型

类型	特征
简单反射型	基于当前感知的规则（ 不看历史 ）
基于模型的反射型	维护内部环境模型
基于目标的	为达到目标考虑可能的行动序列
基于效用的	使用效用函数量化偏好
学习型	通过反馈自动改进

- **表驱动智能体**：查表决定行动，但获取所有条目**很难甚至不可能**
- **简单反射型**：基于当前感知选择行动，**不涉及感知历史、目标、效用**
- **基于目标的**：可能考虑很长行动序列，**不只是短期有利行动**
- **基于效用的**：性能度量反馈信息**不单一**（更通用）
- **学习智能体**：需要行动反馈，从评价器获得反馈
- **理性智能体不是基本类型**（是总称/理想化概念）

机器人

- **基本组成**：传感器、处理器、效应器
- **定义**：具备感知、决策和执行能力的智能系统
- **三大核心模块协作**：传感器 → 处理器 → 效应器
- **有源传感器**：主动发出信号（如激光雷达）

- **无源传感器：**被动接收信号（如普通摄像头）
- **机器人”眼睛”：**红外传感器等
- **处理器：**逻辑推理和决策的核心

本模块核心考点：莫拉维克悖论、强化学习核心（试错 + 奖励）、MDP 五元组、PEAS 描述、环境分类（自动驾驶/围棋等）、智能体类型（5 种）、机器人三大模块。

人工智能安全与伦理

AI 风险分类

风险类型	分类	示例
鲁棒性风险	内生	对抗样本攻击、长尾风险
可解释性风险	内生	黑箱效应、模型推理不透明
公平性风险	内生	历史偏见、对特定群体错误率高
隐私性风险	内生	训练数据泄露、模型反演攻击
可靠性风险	内生	输出与输入无关的内容
有害性风险	内生	生成暴力/色情等内容
就业冲击	衍生	自动化取代传统岗位
学术造假	衍生	滥用 AI 生成虚假论文
虚假新闻	衍生	生成模型伪造新闻误导公众

核心概念详解

鲁棒性（Robustness）

- 模型在噪声、干扰或恶意攻击下仍能保持稳定输出的能力
- 长尾风险：模型在尾部少数情境下缺乏足够训练经验 → 鲁棒性问题
- 对抗训练：通过调整训练过程使模型对输入扰动更鲁棒

可解释性（Explainability）

- 黑箱效应：模型推理过程难以追溯
- 可解释性风险不能忽略（即使不直接导致错误），在高风险领域尤需关注

公平性（Fairness）

- 产生原因：训练数据历史偏见、优化目标忽略公平性约束、缺乏偏见检测
- 面部识别对非洲裔女性错误率较高 → 公平性风险
- 模型优化目标忽略公平性约束 → 加剧对特定群体的系统性偏见

隐私性（Privacy）

- 差分隐私：防范数据泄露的关键技术
- 训练数据未经匿名化处理 → 易泄露敏感信息

攻击方式

攻击类型	描述
对抗样本攻击	在输入上添加微小扰动使模型输出错误
模型窃取攻击	通过黑盒访问接口复制目标模型参数
模型反演攻击	从模型输出反推训练数据信息
成员推断攻击	判断某样本是否在训练集中

风险防范技术

类别	方法	作用
3* 基于数据	数据筛选与清洗 数据增广 数据生成	删除重复/错误数据、修正标注 扩充数据多样性 合成新样本
4* 基于训练策略	指令微调 对抗训练 RAG 价值对齐	使模型更好理解用户意图 提升鲁棒性 引入外部知识减少幻觉 使模型行为符合人类价值观
3* 基于推理	多智能体推理 模型自推理改进 推理过程干预	多 AI 协作提升准确性 自我调节和修正 外部约束和引导

伦理治理原则

- 透明性：向用户说明 AI 决策逻辑与依据
- 公平性：避免系统性偏见
- 隐私保护：差分隐私、匿名化
- 责任与问责：明确责任归属
- 安全与可靠：确保模型输出可靠

灾难性遗忘：模型在微调后丢失原有知识的现象。属于可靠性风险的一种表现。

超级对齐

- 目的：解决未来超级智能体可能超出人类控制的问题
- 需要技术、伦理、法律多层面协同
- 关键目标：平衡技术创新与道德部署
- 需要：政策制定者 + 企业领导者 + 研究人员的协同合作

本模块核心考点：内生风险与衍生风险区分（虚假新闻/就业 → 衍生）、鲁棒性/可解释性/公平性定义与实例、对抗训练、差分隐私、模型窃取攻击、灾难性遗忘、RAG 防幻觉、AI 伦理原则、超级对齐目标。

附录：重要人物与时间线

重要人物一览

人物	贡献	年份
艾伦·图灵	《计算与智能》、图灵测试	1950
麦卡洛克 & 皮茨	M-P 神经元模型	1943
弗兰克·罗森布拉特	感知机	1957
马文·明斯基 & 派珀特	《感知器》，指出单层感知机局限	1969
亚瑟·塞缪尔	机器学习经典定义	1959
弗朗西斯·高尔顿	”回归”概念提出者	19 世纪
约翰·霍普菲尔德	Hopfield 网络，2024 诺贝尔物理学奖	1982
杰弗里·辛顿	BP 算法、2024 诺贝尔物理学奖	1986
杨立昆 (Yann LeCun)	LeNet-5（反向传播 +CNN）	1989
福岛邦彦	Neocognitron（CNN 雏形）	1980
何恺明	ResNet（跳跃连接）	2015

关键事件时间线

年份	事件
1943	M-P 模型（现代 ANN 基础）
1950	图灵发表《计算与智能》
1956	达特茅斯会议，” 人工智能” 概念诞生
1957	罗森布拉特提出感知机
1969	明斯基 & 派珀特指出感知机局限 → 第一次 AI 低谷
1980	福岛邦彦提出 Neocognitron（CNN 雏形）
1982	Hopfield 神经网络
1986	BP 算法提出（Rumelhart, Hinton, Williams）
1989	LeNet-5（最早实际应用的 CNN）
1997	LSTM 提出；深蓝击败国际象棋冠军
2012	AlexNet 在 ILSVRC 夺冠 → 深度学习浪潮开启
2014	GAN 提出（Goodfellow）
2015	ResNet（152 层，跳跃连接）
2016	AlphaGo 击败李世石
2017	Transformer 提出；中国 AI 发展规划
2018	BERT 提出
2020	GPT-3；中国大模型快速发展期
2022	ChatGPT 发布
2024	霍普菲尔德 & 辛顿获诺贝尔物理学奖

附录：易错题重点提示

1. 图灵测试阈值：30%（容易与 20% 混淆）
2. AI 低谷次数：两次（不是一次或三次）
3. 不属于三大学派：生成主义（Generativism）
4. 图灵机不含：仿真器
5. 摩尔定律：18 个月（不是 12 个月）
6. AlexNet 是最早的深度学习模型（不是 GoogLeNet 或 ResNet）
7. BERT 是最早的大模型（不是 GPT-2 或 Turing-NLP）
8. 三元空间不含：仿生学
9. 人工智能核心三要素不含：操作系统（是数据、算法、算力）
10. 大脑神经元数量：860 亿（不是 100 亿）
11. 神经连接数：100 万亿
12. 灰质是智能来源，白质是通信网络
13. 树突接受刺激，轴突传出刺激（容易弄反）
14. MP 神经元不含：池化核
15. XOR 问题：单层感知机无法解决（需要隐藏层）
16. BP 算法核心：链式法则 + 梯度下降
17. ReLU 不能彻底解决死亡神经元问题
18. CNN 未考虑时序变化 → 不适合序列问题
19. ResNet 核心：跳跃连接（残差连接）
20. 万能逼近定理：至少需要一个隐藏层
21. 过拟合：训练低/测试高；欠拟合：两者都高
22. 加大网络复杂度加重过拟合（不会缓解）
23. Early Stopping 不能缓解欠拟合

24. **强化学习**：试错 + 延迟奖励（不是监督学习）
25. **MDP 五元组**不含：学习率
26. **机器人三模块**：传感器 → 处理器 → 效应器
27. **自动驾驶环境**：部分可观察、序列式（非片段式）、动态、连续、多智能体
28. **虚假新闻/学术造假/就业冲击**：衍生风险（非内生风险）
29. **灾难性遗忘**：微调后丢失原有知识
30. **RAG**：检索 + 生成（依赖外部知识库，非依赖模型自身参数）
31. **大脑五叶**：额叶（运动/思维）、顶叶（感觉）、颞叶（听觉/语言）、枕叶（视觉）、岛叶
32. **视觉双通路**：腹侧 = What（内容）、背侧 = Where（空间位置）
33. **Broca** = 语法，**Wernicke** = 语义
34. **语言**主要位于**左半球大脑**

考前温馨提示

复习建议

1. **掌握主线：**AI 发展史 → 脑科学基础 → 神经网络/ML/DL → 应用 (CV/NLP) → 伦理安全
2. **对比记忆：**符号主义/连接主义/行为主义、监督/无监督/强化学习、R-CNN 系列/YOLO
3. **数字记准：**30% (图灵测试)、18 个月 (摩尔定律)、860 亿 (神经元)、100 万亿 (神经连接)
4. **分清”不包含/不属于/错误的是”：**负向选择题是考试重点，本题库中有大量此类题型
5. **关注热点：**DeepSeek、ChatGPT、大模型幻觉、AI 安全与伦理治理
6. **理解原理：**BP 算法 (链式法则)、CNN (局部连接 + 权值共享)、Transformer (自注意力)、LSTM (门控机制)

祝考试顺利！

本讲义涵盖《人工智能导论》全部 10 大知识模块，360 道习题的知识点总结。

建议结合教材和课件深入理解各知识点。